## Regression



#### Index

- 1. Introduction
- 2. Regression model
- 3. Cost function
- 4. Optimization



#### 1. Introduction

#### 회귀분석(Regression Analysis)


: 어떤 결과값이 존재할 때, 그 결과값을 결정할 것이라고 추정되는 입력값과 결과값의 연관관계를 찾아 결과값을 예측하는 기법

#### 회귀모델(Regression model)

$$y = h(x_1, x_2, ..., x_k; \beta_1, \beta_2, ..., \beta_k) + e$$



# 2.1 선형회귀모델 (Linear regression)



$$y_i = \alpha + \beta x_i + \varepsilon_i$$
  

$$y_i = \alpha + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_k x_{ki} + \varepsilon_i$$

- x와 y는 선형관계이다
- 오차항은 N(0,σ²)을 따른다
- 독립변수 \_ 오차항

# 2.1 선형회귀모델 (Linear regression)

$$\mathbf{y} = X\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

where 
$$\mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}$$
,  $X = \begin{pmatrix} \mathbf{x}_1^\mathsf{T} \\ \mathbf{x}_2^\mathsf{T} \\ \vdots \\ \mathbf{x}_n^\mathsf{T} \end{pmatrix} = \begin{pmatrix} 1 & x_{11} & \cdots & x_{1p} \\ 1 & x_{21} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \cdots & x_{np} \end{pmatrix}$ ,  $\boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \vdots \\ \beta_p \end{pmatrix}$ ,  $\boldsymbol{\varepsilon} = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}$ 

$$S(\boldsymbol{\beta}) = (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^T (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})$$
를  $\boldsymbol{\beta}$  에 대해서 Minimize



: 오차항이 정규분포를 따르지 않는 경우를 포함하는 선형모형의 확장 ex) 이항변수

- Random Component : response variable Y
- Systematic Component : X
- Link function : a function of E(Y) related to X  $\mu = E(y)$  를  $g(\mu) = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$ 처럼 linear predictor와 연결시키는 함수



• 
$$g(\mu)=\mu$$
 : identity link function,  $-\infty<\mu<\infty$  
$$\mu=\beta_0+\beta_1x_1+...+\beta_px_p \quad \text{=>} \quad \text{Ordinary Regression}$$

$$g(\mu) = log(\frac{\mu}{1-\mu}) \text{ : logit link function, } 0 \leq \mu < \infty$$

$$log(\frac{\mu}{1-\mu}) = \beta_0 + \beta_1 x_1 + \ldots + \beta_p x_p$$
 => Logistic Regression



$$f(y_i; \theta_i, \phi) = exp\left[\frac{y_i\theta_i - b(\theta_i)}{a(\phi)} + c(y_i, \phi)\right]$$
 
$$\sum_{i=1}^n log f(y_i; \theta_i, \phi) = \sum_{i=1}^n \left[\frac{y_i\theta_i - b(\theta_i)}{a(\phi)} + c(y_i, \phi)\right]$$

만약  $Y \sim f(y; \theta)$ 라면 아래의 식을 유도할 수 있다.

$$E\{\frac{\partial}{\partial \theta}logf(Y;\theta)\} = 0 \quad -E\{\frac{\partial^2}{\partial \theta^2}logf(Y;\theta)\} = E[\{\frac{\partial}{\partial \theta}logf(Y;\theta)\}] \quad (4)$$

GLM density에 대해서 (3)으로부터  $\mu_i=E(Y_i)=b'(\theta)$ 를 유도할 수 있다.

또한, (4)로부터  $Var(Y_i) = b''(\theta_i)a(\phi)$  식을 유도할 수 있다.



또한, (4)로부터  $Var(Y_i) = b''(\theta_i)a(\phi)$  식을 유도할 수 있다.

GLM은  $\eta_i = g(\mu_i) = \boldsymbol{\beta} \mathbf{x}_i$ 와 같이, link function인  $g(\cdot)$ 를 사용해서  $\eta_i = \boldsymbol{\beta} \mathbf{x}_i$ 와  $\mu_i = E(Y_i)$ 를 연결한다.  $\mu_i = b'(\theta_i)$ , hence  $g = b'(\theta_i)^{-1}$ 이고, 이때 g를 canonical link라 부른다.

$$\sum_{i=1}^{n} log f(y_i; \theta_i, \phi) = \sum_{i=1}^{n} \left[ \frac{y_i \theta_i - b(\theta_i)}{a(\phi)} + c(y_i, \phi) \right]$$
(5)

likelihood가 (5)와 같기 때문에, 이를 베타에 대해 미분한 결과를 0으로 두고 계산한다.

$$\frac{\partial L(\boldsymbol{\beta})}{\partial \beta_j} = \sum_i \frac{\partial L_i}{\partial \beta_j} = 0$$

$$\Rightarrow \sum_{i=1}^N \frac{(y_i - \mu_i)x_{ij}}{var(Y_i)} (\frac{\partial \mu_i}{\partial \eta_i}) = 0 \quad \mu_i = g^{-1}(\sum_j \beta_j x_{ij})$$



# 2.2.1 로지스틱 회귀 (Logistic Regression)

: 종속변수가 0과 1의 값을 갖는 이항변수일 때 사용하는 모형  $(\hat{y} = P(y = 1))$ 

$$y = p(\mathbf{x}) = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p, \quad 0 < p(\mathbf{x}) < 1$$
 
$$\ln \frac{p(\mathbf{x})}{1 - p(\mathbf{x})} = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p, \quad 0 < p(\mathbf{x}) < 1 \quad f(\mathbf{x}) = \frac{1}{1 + e^{-\beta \mathbf{x}}}$$
 
$$p(\mathbf{x}) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p)}} = \frac{1}{1 + e^{-\beta \mathbf{x}}}, \quad 0 < p(\mathbf{x}) < 1$$



# 2.2.1 로지스틱 회귀 (Logistic Regression)

만약  $n_i y_i \sim^{iid} Binomial(n_i, p_i)$ 이라면,

$$f(y_i; p_i, n_i) = \binom{n_i}{n_i y_i} \pi_i^{y_i} (1 - \pi_i)^{n_i - n_i y_i} = exp\left[\frac{y_i \theta_i - log\{1 + exp(\theta_i)\}}{1/n_i} + log\binom{n_i}{n_i y_i}\right]$$

where 
$$\theta_i = log\{\frac{\pi_i}{1-\pi_i}\}$$
,  $b(\theta_i) = log\{1 + exp(\theta_i)\}$ , and  $a(\phi) = 1/n_i$ 

$$E(Y_i) = b'(\theta_i) = \frac{\partial}{\partial \theta_i} log\{1 + exp(\theta_i)\} = \frac{exp(\theta_i)}{1 + exp(\theta_i)} = \pi_i$$

$$Var(Y_i) = b''(\theta_i)a(\phi) = \frac{exp(\theta_i)}{\{1 + exp(\theta_i)\}^2 n_i} = \pi_i(1 - \pi_i)/n_i$$

$$\eta_i = g(\mu_i) = \theta_i = (b')^{-1}(\mu_i) = log \frac{\pi_i}{1 - \pi_i} = \beta \mathbf{x}_i$$
 (link function)


#### 3. Cost function

: 실제값과 예측값의 차이에 대한 함수



### 3.1 MSE (Mean Square Error)


$$residual = y - \hat{y}.$$



$$\sum_{i=1}^{n} r_i^2 = \sum_{i=1}^{n} (y_i - f(x_i))^2$$




#### 3.1 MSE (Mean Square Error)




$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$$

$$MSE = \frac{1}{m} \sum_{i=1}^{m} (y - \hat{y})^2$$

## 3.2 Cross Entropy









#### 3.2 Cross Entropy

Cross Entropy = 
$$-\frac{1}{m} \left[ \sum_{i=1}^{m} y^{i} \cdot log \widehat{y}^{i} + (1 - y^{i}) \cdot log (1 - \widehat{y}^{i}) \right]$$

$$L(y, \hat{y}) = -[y\log(\hat{y}) + (1 - y)\log(1 - \hat{y})]$$







#### 4. Optimization: Gradient Descent

Optimization : 어떤 목적함수의 함숫값을 최적화하는 모수를 찾는 문제 Gradient Descent : 기울기가 0일 부분을 찾아가는 알고리즘



### 4. Optimization: Gradient Descent

